SCRAPING + PARSING FROM SCRATCH.

El Web Scraping tiene que ver con el concepto de extraer o recolectar datos desde sitios web, directo desde su código HTML, con el objetivo estructurar dichos datos en un formato que sea manejable.

En otras palabras, es recolectar información publica relvante desde las páginas de un sitio, la que podremos estructurar de manera tal que, a posterior se podrá utilizar para llevar a cabo análisis más interesantes.

El Web Scraping nos permitirá estructurar información publicada en sitios mediante páginas HTML (“información de dominio público”), sin tener la necesidad de utilizar una API o mecanismo que nos entregue los datos bajo un formato. En mi opinión, siempre es recomendable utilizar las API en caso de que éstas existan.

Desde un punto de vista técnico, el Web Scraping lo podemos hacer con cualquier lenguaje de programación que tenga las API's y librerias que permitan realizar las siguientes acciones:

1. Conectarse a una dirección en la web.
2. Leer el HTML de la URL especificada.
3. Identificar patrones dentro del HTML.
4. Extraer los datos relevantes y estructurarlo en un formato.
5. Persistir la información en un motor de persistencia (como una BD NoSQL, por ejemplo) para futuros análisis.

Esquemáticamente la aplicación debe ejecutar la siguiente secuencia de acciones.

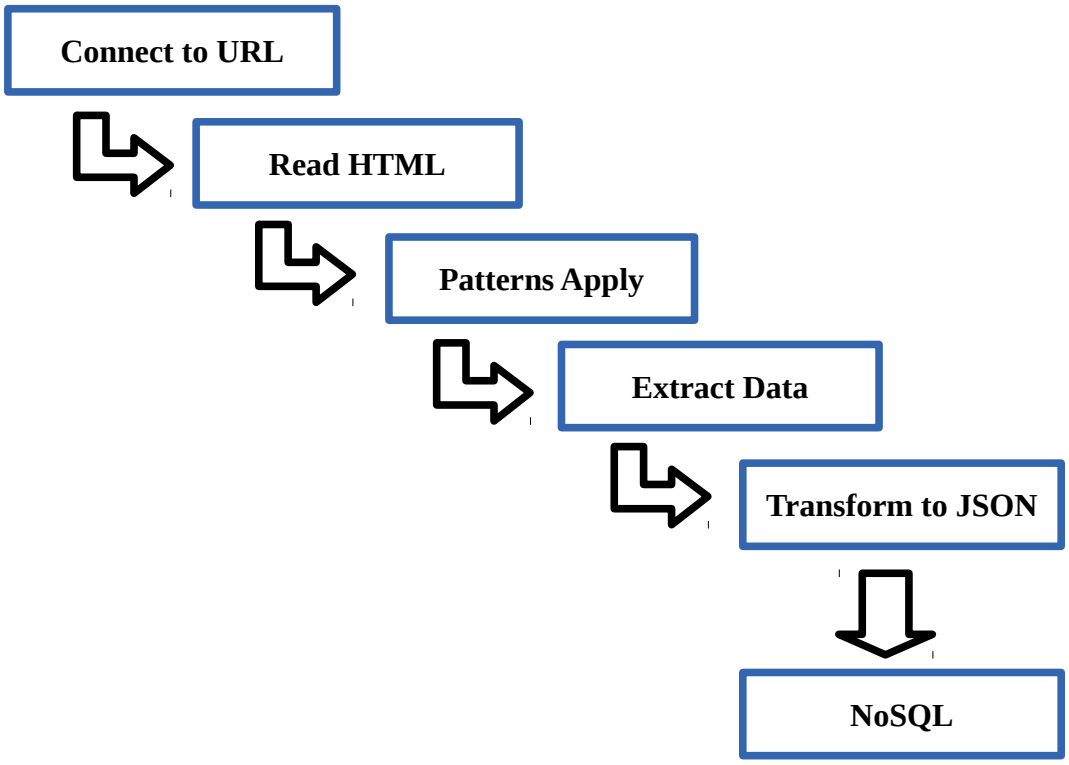

SCRAPING STACKOVERFLOW.

El siguiente ejemplo está desarrollado en Python utilizando las librerias y módulos propios de Python. Los principales son:

1. **Módulo httplib**, el cual nos permite conectarnos a una URL y leer las páginas HTML.
2. **Módulo re,** el cual nos permite aplicar patrones de búsqueda mediante el uso de expresiones regulares, permitiendonos encontrar y extraer los datos relevantes desde el código HTML.
3. **Módulo json**, para formatear la representación de los datos en formato JSON.
4. **Módulo datetime**, para registrar la hora en que se ejecuta el web scraping sobre el sitio.

La aplicación extrae las preguntas publicadas en http://stackoverflow.com/ transformando el HTML que “muestra” las preguntas, junto con los votos (votes), respuestas (answers), las vistas (views) y los tags asociados a las preguntas al formato JSON.

A contiinucación podemos apreciar la página del sitio stackoverflow.com y como la información relativa a las preguntas son estructuradas bajo un formato JSON.

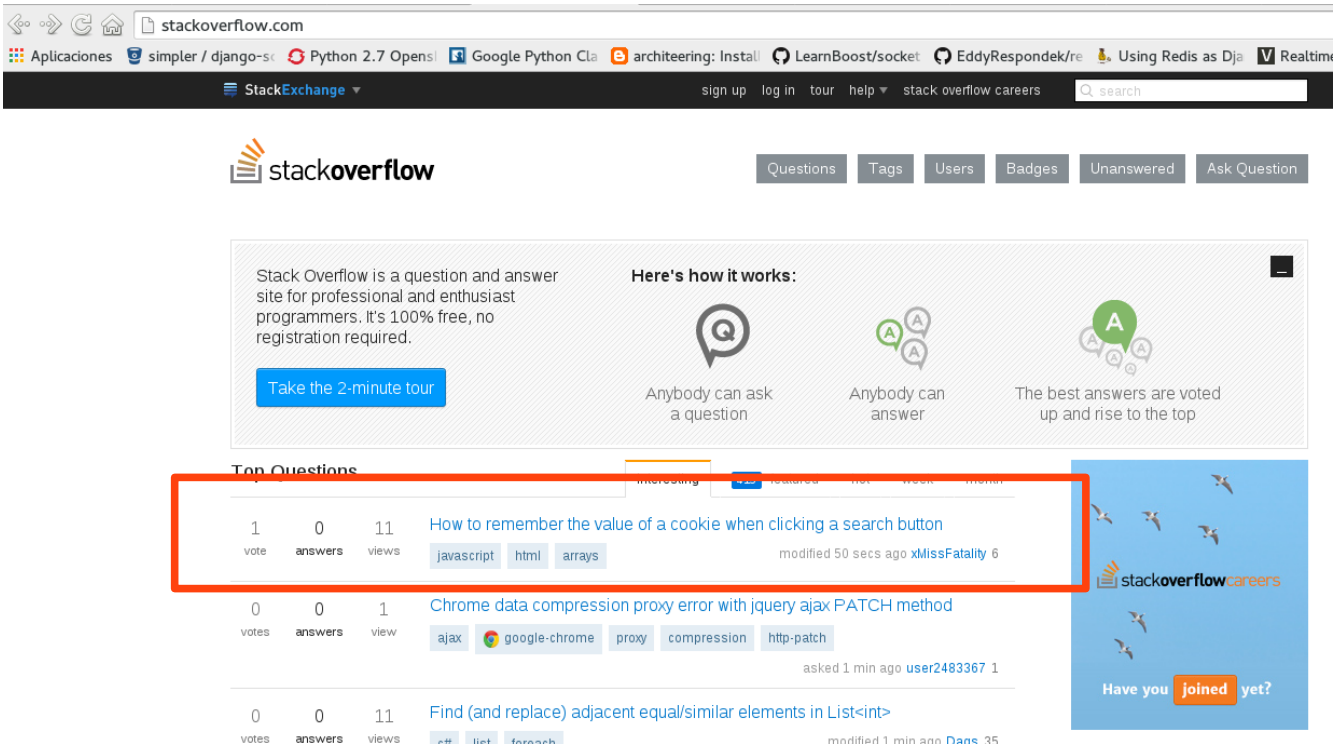


```
{
   "answers": "0",
   "id_question": "28653551",
   "question": "How to remember the value of a cookie when clicking a search button",
   "tags": [
      "javascript",
      "html",
      "arrays"
```

```
    ],
    "timestamp": "2015-02-21 23:27:48.146811",
    "views": "11",
    "votes": "1"
}
```


Nota: El ***timestamp*** es puesto por la aplicación para indicar en que momento se realiza el proceso de extracción y transformación.

La aplicación genera como salida una lista con todas las preguntas (junto con su metadata) que están publicadas en la url http://stackoverflow.com/

El código de la aplicaicón y como se utiliza se puede ver en la siguiente URL:

https://github.com/rancavil/laboratory/tree/master/scraping

Descripción de las funcioens.

Función fetch_page():

La función fetch page realiza la conexión al sitio www.stackoverflow.com mediante el uso de la librería Python httplib, recuperando la página HTML principal, retornandola como un String de caracteres.

Función parse_html():

Esta función recibe como parámetro el HTML recuperado por la función fetch_page() y lo empieza a analizar mediante la aplicación de patrones de bśuqeda definidos con expresiones regulares.

Se utiliza una expresión regular junto con la función finditer() del módulo de Python re, que permite encontrar, dentro del HTML las preguntas.

El patrón de búsqueda, junto con el uso de la función re.finditer(), devuelve una lista con todos los estractos de código HTML que cumple con dicho patrón y que corresponde a las preguntas publicadas en el sitio.

En cada iteración se llama a la función extract_data_2_json() la cual extrae los datos desde el trozo de HTML que corresponde a la pregunta.

Función extract_data_2_json():

La función recibe como parámetro un fragmento del código HTML correspondiente a la pregunta, lo analiza y extrae, mediante el uso de patrones de búsquedas definidos a través de expresiones regulares, los datos que se requieren y crea una representación en formato JSON (diccionario de Python).

Retorna un objeto diccionario de Python.

Función find_all_tags():

Esta función busca todos los tags relativos a una pregunta, retornando una lista con los tags encontrado.